

卒業論文

視覚と行動の end-to-end 学習により 経路追従行動をオンラインで模倣する手法の提案 (目標方向による経路選択機能の追加と検証)

A proposal for an online imitation method of path-tracking

behavior by end-to-end learning of vision and action

(Addition of path selection function and verification by target direction)

2022 年 12 月 13 日 提出

指導教員 林原 靖男 教授

千葉工業大学 先進工学部 未来ロボティクス学科

19C1101 藤原 柁

概要

視覚と行動の end-to-end 学習により 経路追従行動をオンラインで模倣する手法の提案 (目標方向による経路選択機能の追加と検証)

近年, カメラ画像に基づいた自律走行の研究が行われている. 本研究室でも, 測域センサを用いた自律移動システムの出力を教師信号として与えることでロボットの経路追従行動をオンラインで模倣する手法を提案されている. また, 実験によりカメラ画像に基づいた自律走行で, 一定の経路を周回することが可能であることが示されている. 提案手法では, 目標の進行方向をデータセットと学習器の入力に加えることで, 「直進」や「左折」などの経路が選択できる分岐路において, 任意の経路を選択可能にする機能の追加を提案する. 提案手法では, 測域センサを用いた自律移動システムの出力をカメラ画像と目標とする進行方向を示すデータ (以下, 「目標方向」と称する) を用いて模倣学習する. 学習後, カメラ画像と目標方向に基づいて任意の経路を選択可能な自律走行を行う. また, シミュレータを用いた実験と実環境での実験により, 提案手法の有効性を検証した. その結果, 任意の経路を選択し, カメラ画像に基づく自律走行が行えることを確認した.

キーワード: end-to-end 学習, Navigation, 目標方向

abstract

A proposal for an online imitation method of path-tracking
behavior by end-to-end learning of vision and action
(Addition of path selection function and verification by target direction)

In recent years, research on autonomous driving based on camera images has been conducted. In this research laboratory, a method of online imitation of robot path following behavior by giving the output of an autonomous moving system using range sensor as a teacher signal has been proposed. Furthermore, experiments have shown that it is possible to circulate a certain route based on autonomous driving using camera images. In the proposed method, by adding the target progress direction to the input of the dataset and the learning machine, it is possible to add a function that enables the selection of arbitrary routes at branching roads where routes such as "straight ahead" and "turn left" can be selected. In the proposed method, we propose to learn the imitation of camera images and target direction using the output of the autonomous moving system using range sensor. After learning, autonomous driving that can select arbitrary routes based on camera images and target direction is performed. In addition, the effectiveness of the proposed method was verified by experiments using a simulator and experiments in an actual environment. As a result, it was confirmed that arbitrary routes can be selected and autonomous driving based on camera images can be performed.

keywords: End-to-end learning, Navigation, Target direction

目次

第 1 章	序論	1
1.1	背景	1
1.1.1	RoboCup	1
第 2 章	要素技術	2
2.1	Deep learning	2
2.2	end-to-end 学習	3
2.3	Convolution Neural Network	4
2.4	地図を用いたルールベースの制御器	6
2.5	従来手法	7
2.5.1	学習フェーズ	8
2.5.2	テストフェーズ	9
第 3 章	提案手法	10
3.1	提案手法の概要	10
3.2	学習フェーズ	11
3.3	テストフェーズ	12
3.4	目標方向	13
3.5	ネットワーク構造	14
参考文献		15
付録		16

目次	vi
----	----

謝辭	17
----	----

目次

1.1	Example	1
2.1	Neural network	2
2.2	Structure of end-to-end learning	3
2.3	AlexNet from [1]	4
2.4	VGG from [1]	5
2.5	A rule-based controller using a map	6
2.6	7
2.7	Output of rule-based controller using a map and actual robot behavior .	8
2.8	Test phase of conventional method	9
3.1	Learning phase system of proposed method	11
3.2	Overview learning phase	11
3.3	Learning phase system of proposed method	12
3.4	Target direction	13
3.5	Method network	14

表目次

2.1	Angular velocity offset	8
3.1	Target direction list	13
3.2	14

第 1 章

序論

1.1 背景

1.1.1 RoboCup



Fig. 1.1 Example

etc...

第 2 章

要素技術

本章では、本研究で用いた深層学習に関連した要素技術と、ベースとなる従来手法について述べる。

2.1 Deep learning

Deep learning は、画像や音声などのデータに特に適しており、近年では自然言語処理などさまざまな分野で活用されている。人間の脳のような深い層の構造を持つ人工ニューラルネットワークに基づく機械学習手法である。人工ニューラルネットワークは、入力データから出力データを予測するために、多数のニューロンを用いて情報を処理する。この人工ニューラルネットワークを多層構造にすることで、より深い情報処理を行うことができる。これにより、高度な識別や分類タスクなどを行うことを可能にしている。一般的な構造を Fig. 2.1 に示す。




Fig. 2.1 Neural network

2.2 end-to-end 学習

end-to-end 学習とは, 人工ニューラルネットワークを使用して, 入力データから出力を直接生成する方法のことを指す.

実世界における自動運転を例に挙げる. end-to-end 学習を用いない場合, 人物や障害物などの物体認識, 車線の検出, 経路計画, ステアリングの制御など, 多くのタスクを解決する必要がある. しかし, end-to-end を用いることで, 先程のタスクを解決することなく, 車両が撮影したカメラ映像から直接, 運転操作を行うことができる.




Fig. 2.2 Structure of end-to-end learning

2.3 Convolution Neural Network

畳み込みニューラルネットワーク (convolutional neural network:CNN) は人工ニューラルネットワークのモデルの一種である。このモデルは、画像や音声などの多次元の配列で表される複雑なデータを処理するために特別に設計されている。CNN は次のような特徴を持つ層で構成されている。

1. 畳み込み層

入力データをフィルタ（カーネル）を用いて特徴を抽出する。

2. プーリング層

特徴を残しつつ、畳み込み層の出力を圧縮する。これにより、画像であればピクセル数が減少し、計算量が大幅に減らすことができる。

3. 全結合層

畳み込み層とプーリング層の出力をまとめて処理する。

Krizhevsky ら [1] は Fig. 2.3 で示すような、8 つの層からなるネットワークを用いて、15 万の高解像度画像を 1,000 の異なるクラスに分類するタスクをエラー率 15.3% で達成し、画像分類コンペティションである ILSVRC(ImageNet Large Scale Visual Recognition Competition)2012 で優勝をおさめた。




Fig. 2.3 AlexNet from [1]

Simonyan らは CNN の層の深さが精度に与える影響を調査した。最大 19 層の深い畳み込みネットワークを評価した結果、モデルを深層にすることが分類精度に有利であることが示された。ILSVRC2012 の優勝モデルである AlexNet は 8 層、ILSVRC2013 で提案された ZFNet は同様の 8 層であることから、当時の CNN としては圧倒的に深い層を持つモデルであった。このような深い畳み込みネットワークは、深層学習における重要な発展の一つとされている。

ConvNet Configuration					
A	A-LRN	B	C	D	E
11 weight layers	11 weight layers	13 weight layers	16 weight layers	16 weight layers	19 weight layers
input (224 × 224 RGB image)					
conv3-64	conv3-64 LRN	conv3-64 conv3-64	conv3-64 conv3-64	conv3-64 conv3-64	conv3-64 conv3-64
maxpool					
conv3-128	conv3-128	conv3-128 conv3-128	conv3-128 conv3-128	conv3-128 conv3-128	conv3-128 conv3-128
maxpool					
conv3-256 conv3-256	conv3-256 conv3-256	conv3-256 conv3-256	conv3-256 conv3-256 conv1-256	conv3-256 conv3-256 conv3-256	conv3-256 conv3-256 conv3-256 conv3-256
maxpool					
conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512 conv1-512	conv3-512 conv3-512 conv3-512	conv3-512 conv3-512 conv3-512 conv3-512
maxpool					
conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512 conv1-512	conv3-512 conv3-512 conv3-512	conv3-512 conv3-512 conv3-512 conv3-512
maxpool					
FC-4096					
FC-4096					
FC-1000					
soft-max					

Fig. 2.4 VGG from [1]

2.4 地図を用いたルールベースの制御器

従来手法と提案手法において、教師信号として用いる地図ベースの制御器について述べる。地図ベースの制御器は、ROS Navigation_stack[2] へ移動目標の経由地点 (waypoint) の指示を行う waypoint_nav[3] を組み合わせたものである。ROS Navigation_stack では以下のような処理が行われる。

- ロボットの現在位置を推定する
- 移動目標地点までの経路を決定する
- 経路にしたがった行動をロボットに指示する

また、Fig. 2.2 に示すように、事前に生成した占有格子地図と測域センサ、オドメトリを用いて、地図上での自己位置推定を Particle_Filter によって確率的に行う「amcl」。障害物認識などによる局所的、または地図全体の大域的なコスト計算、その結果に基づいた経路計画、それに従ったモータ指令を行う「move_base」などのパッケージを統合した自律走行用のメタパッケージである。従来手法、提案手法ともにモータ指令を並進速度と角速度にわけた。並進速度は一定とした。

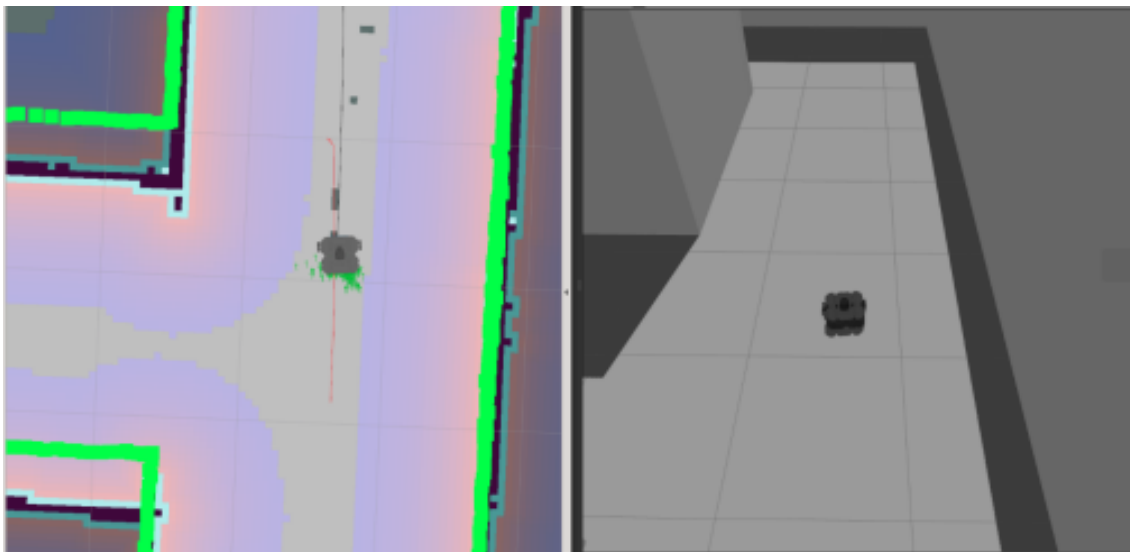


Fig. 2.5 A rule-based controller using a map

2.5 従来手法

本研究のベースとなる岡田らの研究について述べる。先に述べたように、本論文では岡田らの手法を「従来手法」と呼ぶ。従来手法は、地図を用いたルールベース制御器が生成した走行を模倣学習し、似た行動を画像を用いて行う手法である。

Fig. 2.6 に、経路追従行動を視覚に基づいてオンラインで模倣するシステムを示す。手法は模倣学習により、学習器の訓練をする学習フェーズと訓練した結果を検証するテストフェーズに分かれる。なお、両フェーズで用いる並進速度は一定の値を用いる。




Fig. 2.6

2.5.1 学習フェーズ

学習フェーズは、模倣学習によって学習器の訓練を行うフェーズである。地図を用いたルールベース制御器に、測域センサとオドメトリのセンサ入力で自律走行を行う。具体的には、ROS navigation_stack パッケージを利用して、ロボットに自律移動させる。学習フェーズでは、ロボットの中央、左、右に傾けて取り付けられた 3 つのカメラを用いて画像を取得する。自律移動させる際に、取得するデータ量を増加させること及び、過学習の抑制を目的として、Table 2.1 に示すような処理を行う。また、地図を用いたルールベース制御器の出力をそのまま模倣学習するのではなく、少し蛇行するように自律移動させることで、経路に戻るような挙動も学習できるようになっている。Fig. 2.7 に示すように、実際にロボットを制御する行動と経路に沿う行動を別に扱うことで、常に経路に沿う行動をデータセットに加えることを可能にしている。岡田らの手法では、データセットの収集方法にいくつかのバリエーションがあるが、本論文では前報 [4] において最も経路追従の成功率が高い手法を用いて、ロボットに模倣学習をさせる。

Table 2.1 Angular velocity offset

Left camera	Angular velocity of a rule-based controller using a map + 0.2 rad/s
Center camera	Angular velocity of a rule-based controller using a map
Right camera	Angular velocity of a rule-based controller using a map - 0.2 rad/s




Fig. 2.7 Output of rule-based controller using a map and actual robot behavior

2.5.2 テストフェーズ

学習器の訓練後, Fig. 2.8 で示すテストフェーズへ移行する. このフェーズでは, 学習器にカメラ画像を入力し, 出力されるヨー方向の角速度を用いて自律移動することで, 訓練後の学習結果を評価する. なお, テストフェーズでは中央のカメラのみを用いる.




Fig. 2.8 Test phase of conventional method

第 3 章

提案手法

本章では, 従来手法をベースとする提案手法を提案手法の概要, 提案手法における学習フェーズ, テストフェーズ, 用いた目標方向とネットワーク構造についての 5 節にわけて述べる.

3.1 提案手法の概要

従来手法で用いたデータセットと学習器の入力へ, 「直進」「左折」などの目標方向を追加する. これにより, 学習器の出力による自律移動において, 経路を選択する機能の追加を行った. なお, 追加した要素以外は従来手法と同様である.

3.2 学習フェーズ

提案手法で用いる学習フェーズを Fig. 3.1 に示す．経路追従行動を行う地図ベースの制御器から目標方向を生成し，データセットに加えている．提案手法では，Fig. 3.2 に示すように LiDAR とオドメトリを入力とする地図ベースの制御器による経路追従行動を，カメラ画像と目標方向を用いて模倣学習する．

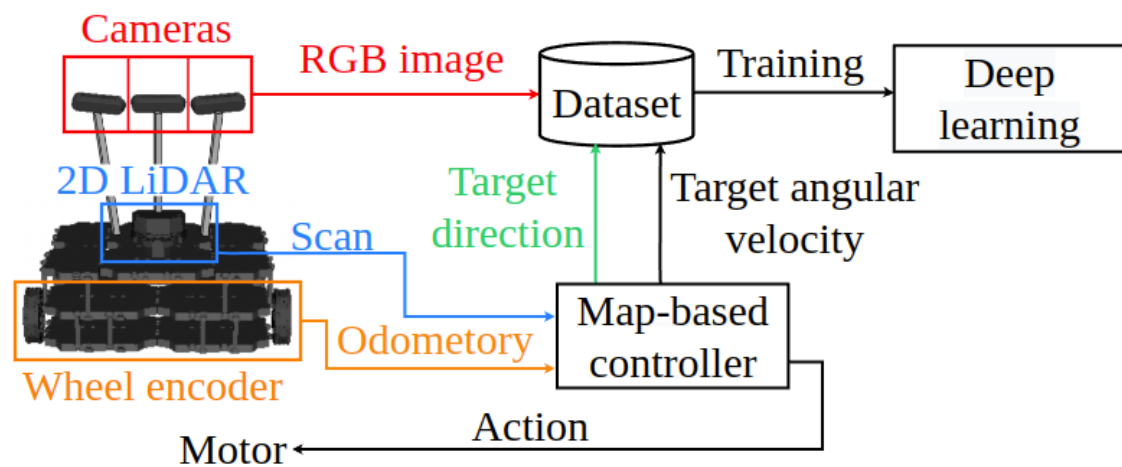


Fig. 3.1 Learning phase system of proposed method




Fig. 3.2 Overview learning phase

3.3 テストフェーズ

提案手法におけるテストフェーズでは Fig. 3.3 で示すように, 学習器の入力へ目標方向を加えた. なお, テストフェーズも学習フェーズと同様に, 地図を用いたルールベース制御器から目標方向を生成している. 本来ならば, 目的地までカメラ画像のみで自律移動するためには, 目標方向を画像から自動的に作成する仕組みが必要となる. fig に動作の様子を示す. カメラ画像と目標方向を入力した学習器の出力による自律走行時, 目標方向によって任意の経路を選択する.

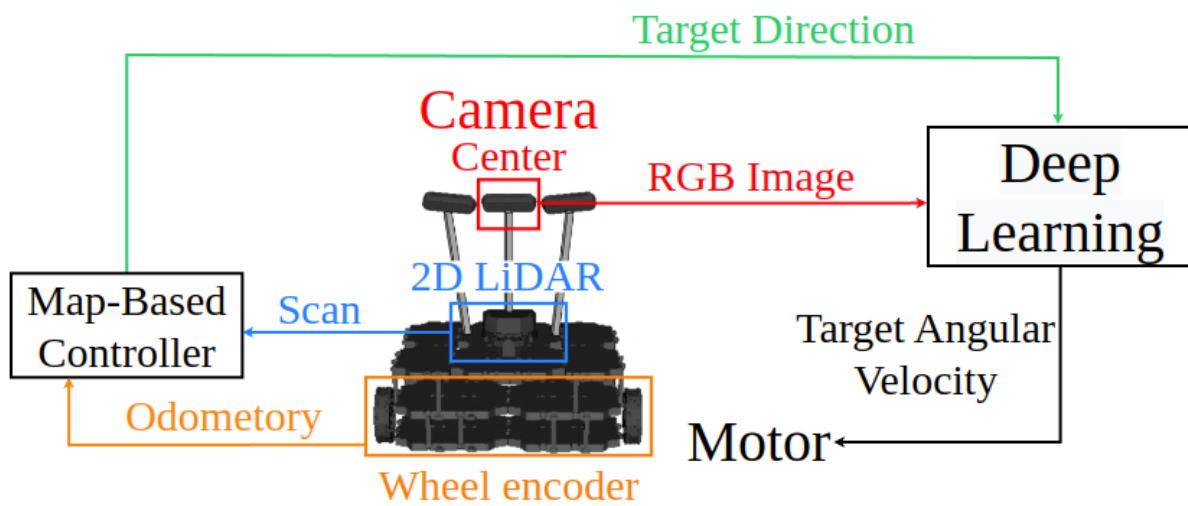


Fig. 3.3 Learning phase system of proposed method

3.4 目標方向

本研究で用いた目標方向と、そのデータ形式である目標方向指令について述べる。目標方向を Fig. 3.4 に示す。経路と分岐路において「道なり」に走行 (Go straight), 分岐路において「直進 (Go straight)」, 「左折 (Turn left)」, 「右折 (Turn right)」の3つとする。




Fig. 3.4 Target direction

学習器には、上記の3つの目標方向を要素数3、次元数1のint型の配列で表現した”目標方向指令”を入力する。目標方向指令のデータ形式を Table 3.1 に示す。

Table 3.1 Target direction list

Target Direction	Go straight	Turn left	Trun right
Data	[100, 0, 0]	[0, 100, 0]	[0, 0, 100]

3.5 ネットワーク構造

提案手法で用いた学習器のネットワークを Fig. 3.5 に示す. また, ハイパーパラメータについて table に示す. 64x48 の RGB 画像を入力とする入力層 1 層, 畳み込み層 3 層, 全結合層 2 層を持つ 6 層の CNN と, この CNN の出力と目標方向指令を入力する入力層 1 層, 全結合層 2 層, 出力層 1 層の全 10 層から構成されている. 出力はヨー方向の角速度である.

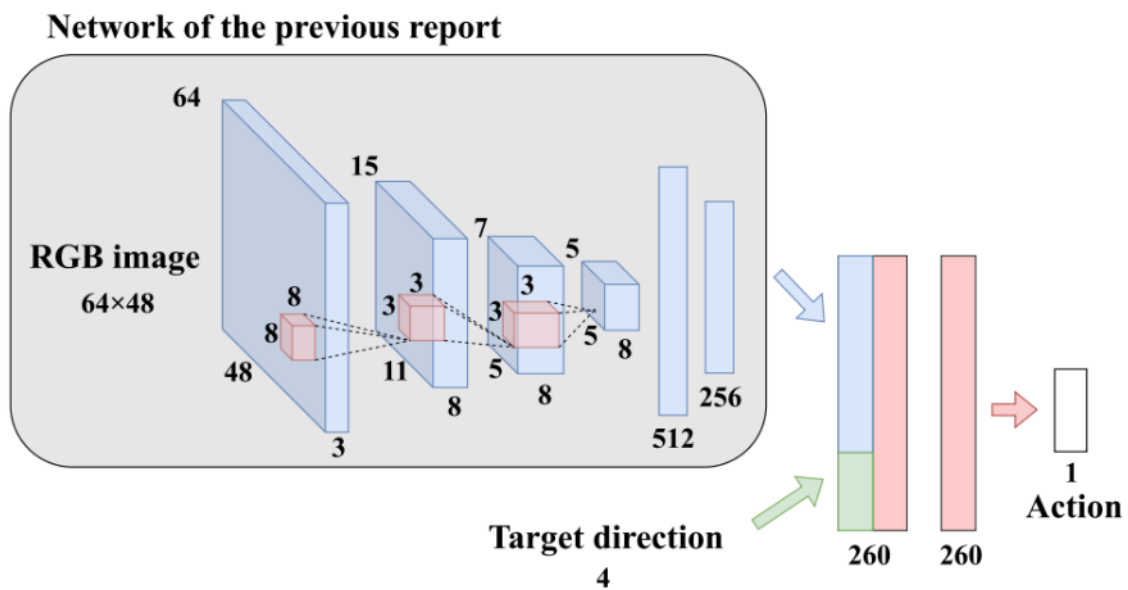


Fig. 3.5 Method network

Table 3.2

Input data	Image(64x48 pixels, RGB channels), Target direction
Optimizer	Adam($\alpha = 0.001, \beta_1 = 0.9, \beta_2 = 0.999, \epsilon = 1e^{-1}$)
Loss function	Softmax-cross-entropy
Output data	Angular velocity

参考文献

- [1] I. sutskever a. krizhevsky and g. e. hinton. imagenet classification with deep convolutional neural networks. pp. 2p1-j07. 一般社団法人 日本機械学会, 2017.
- [2] ros-planning, navigation レポジトリ. <https://github.com/ros-planning/navigation>. (Accessed on 12/6/2022).
- [3] waypoint_nav レポジトリ. https://github.com/open-rdc/waypoint_nav.git. (Accessed on 12/6/2022).
- [4] 岡田眞也, 清岡優祐, 春山健太, 上田隆一, 林原靖男: “ 視覚と行動の end-to-end 学習により経路追従行動 をオンラインで模倣する手法の提案-経路追従行動の修正のためにデータセットを動的に追加する手法の検討 ”, 計測自動制御学会 si 部門講演会 sice-si2021 予稿集, pp.1066-1070(2021).
- [5] 岡田眞也, 清岡優祐, 上田隆一, 林原靖男 “ 視覚と行動の : end-to-end 学習により経路追従行動 をオンラインで模倣する手法の提案 ”, 計測自動制御学会 si 部門講演会 sice-si2020 予稿集, pp.1147-1152(2020).

付録

謝辞

本研究を進めるにあたり，1年に渡り，熱心にご指導を頂いた林原靖男教授に深く感謝いたします．